

BATCH LESSON : PANDAS DATE

B150 Data Science

03.04.2023

SUBJECT: Session 1- Introduction

ZOOM GİRİŞLERİNİZİ LÜTFEN **LMS** SİSTEMİ ÜZERİNDEN YAPINIZ
























Veri bilimi projeleri, verinin keşfedilmesi ve temizlenmesi ile başlar ve bu işlemler projelerin en çok zaman alan kısımlarıdır

Dolayısıyla verinin keşfi ve temizlenmesi sırasında işleri kolaylaştıracak bir takım kütüphanelere ihtiyaç duyulur.

Hatırlayacağınız üzere Numpy verilerle çalışmayı oldukça kolaylaştırmıştı.

Numpy'ın eksik kaldığı kısımlarda ise imdadımıza Pandas yetişiyor.

Ancak Pandas Numpy'ın bir alternatifi olarak değil, uzantısı olarak düşünülmelidir.

Pandas, Numpy'ın sütun adları ve homojen olmayan verilerle çalışamama gibi eksik kaldığı kısımlara ve daha fazlasına çözümler üretir.

Pandas ile veri analizi yaparken kullanacağımız temel veri yapıları Seriler ve DataFrame'lerdir.



Pandas = Panel Data System

Pandas, Python programlama dili için yüksek performanslı, kullanımı kolay veri yapıları ve veri analiz araçları sağlayan açık kaynaklı bir kütüphanedir.


Pandas, Numpy'ın sütun adları ve homojen olmayan verilerle çalışamama gibi eksik kaldığı kısımlara çözümler üretir.

Pandas ile veri analizi yaparken kullanacağımız temel veri yapıları Seriler ve DataFrame'lerdir.



01 01

PANDAS



Used for:

- Data Analysis
- Data Manipulation
- Data Visualization



Pandas Data Types

- Series
- DataFrame
- Panel

Data Structure	Dimensions	Description
Series	1	1D labeled homogeneous array, sizeimmutable.
Data Frames	2	General 2D labeled, size-mutable tabular structure with potentially heterogeneously typed columns.
Panel	3	General 3D labeled, size-mutable array.



Data Structure	Dimensionality	Format		'	View		
Series	1D	Column	name 0 Rukshan 1 Prasadi 2 Gihan 3 Hansana	0 1 2 3	age 25 25 26 24	0 1 2 3	marks 85 90 70 80
DataFrame	2D	Single Sheet	name 0 Rukshan 1 Prasadi 2 Gihan 3 Hansana	age 25 25 26 24	marks 85 90 70 80		
Panel	3D	Multiple Sheets	nam 0 Ruks 1 Pras 2 Giha 3 Hans	han adi n	age 1 25 25 26 24	marks 85 90 70 80	

Image Copyright: Rukshan Pramoditha



Pandas Serileri

Pandas Serisi, NumPy dizi nesnelerinin üzerine inşa edilmiştir ve çok benzerler.

Herhangi bir veri tipinde veri tutabilen tek boyutlu etiketli bir dizidir.

Etiket değerlerine ise indeks denir.

Verinin kendisi sayılar, dizeler veya başka Python objelerinden oluşabilir.


Serileri oluşturmak için ise listeler, sıralı diziler ya da sözlükler kullanılabilir.






Series

- One-dimensional data (Values)
- Index



pandas.Series (data, index, dtype, copy)

pd.Series([85, 90, 70, 80], name='marks')





Pandas Series

10 23 56 17 52 61 73 90 26 72

s = pd.Series(np.random.randn(5), index=["a", "b", "c", "d", "e"])

a 0.469112

b -0.282863


c -1.509059

d -1.135632

e 1.212112

dtype: float64





01 01 01


index

PANDAS

20

30

dtype: int64





Pandas DataFrame

Pandas Dataframe, satırları ve sütunları olan iki boyutlu etiketli veri yapısıdır.


Pandas DataFrame'deki her sütun bir Pandas Serisidir.


Verinin kendisi sayılar, dizeler veya başka Python objelerinden oluşabilir.

Serileri oluşturmak için ise listeler, sıralı diziler ya da sözlükler kullanılabilir.











Pandas DataFrame

Name	Age	Gender	Score
Ali	32	Male	3.45
Ayşe	28	Female	4.6
Hasan	45	Male	3.9
Fatma	38	Female	2.78

```
d = {
"one": pd.Series([1.0, 2.0, 3.0], index=["a", "b", "c"]),
"two": pd.Series([1.0, 2.0, 3.0, 4.0], index=["a", "b", "c", "d"]),
}
```

```
one two
df = pd.DataFrame(d)
a 1.0 1.0
b 2.0 2.0
c 3.0 3.0
d NaN 4.0
```

DataFrame

 DataFrame is a two-dimensional array with heterogeneous data. For example,

Name	Age	Gender	Rating
Steve	32	Male	3.45
Lia	28	Female	4.6
Vin	45	Male	3.9
Katie	38	Female	2.78

Data Type of Columns

Column	Туре
Name	String
Age	Integer
Gender	String
Rating	Float



Pandas Data Structures

Series

index	value	30
IIIUGA	vaiue	70

Α	6
В	3.14
С	-4
D	0

index	\Leftrightarrow	columns =	\Rightarrow
IIIUUUA	_	Columnia -	

	foo	bar	baz
Α	x	6	True
В	у	10	True
С	z	NaN	False

Series

apples 0 3 1 2 2 0 3 1

Series

	oranges
0	0
1	3
2	7
3	2

	apples	oranges
0	3	0
1	2	3
2	0	7
3	1	2

Creating Series

```
import pandas as pd
s1 = pd.Series([1, 2, 3, 4])
```

```
s2 = pd.Series([1, 2, 3, 4], index=['A', 'B', 'C', 'D'])
```

0	1
1	2
2	3
3	4

Α	1
В	2
С	3
D	4



Series Create

- A one-dimensional ndarray
- A Python list

- A Python dictionary
- A scalar value

	1	2
INPUT	Array=np.arange(1,10,2) Ser=pd.Series(array) Ser	data = np.array(['a','b','c','d']) s = pd.Series(data,index=[100,101,102,103]) print s
OUTPUT	0 1 1 3 2 5 3 7 4 9 Dtype: int32	100 a 101 b 102 c 103 d dtype: object



Using a Python dictionary and Scalar

	1	2	3
IN	data = {'a' : 0., 'b' : 1., 'c' : 2.} s = pd.Series(data) print s	data = {'a' : 0., 'b' : 1., 'c' : 2.} s = pd.Series(data,index=['b','c','d','a']) print s	s = pd.Series(5, index=[0, 1, 2, 3]) print s
OUT	a 0.0 b 1.0 c 2.0 dtype: float64	b 1.0 c 2.0 d NaN a 0.0 dtype: float64	0 5 1 5 2 5 3 5 dtype: int64

an index must be provided.



Series Indexing-Slicing

		2
IN	s = pd.Series([1,2,3,4,5],index = ['a','b','c','d','e'])	s[:3]
OUT	a 1 b 2 c 3 d 4 e 5 dtype: int64	a 1 b 2 c 3 dtype: int64



Retrieve Data Using Label (Index)

a 1 b 2 c 3 d 4 e 5 dtype: int64

	1	2
IN	s['a']	s[['a','c','d']]
OUT	1	a 1 c 3 d 4 dtype: int64



Accessing Element

```
ser
1st
2nd
3rd
4th
5th
dtype: int32
ser[[0, 2, 4]] # or ser[['1st', '3rd', '5th']]
1st
3rd
5th
dtype: int32
```

```
1st 1
2nd 3
3rd 5
4th 7
5th 9
dtype: int64
```

```
ser[ser > 3]

3rd      5
4th      7
5th      9
dtype: int64
```



ser

1st 1 2nd 3 3rd 5 4th 7 5th 9

dtype: int64

ser[2:] = 100 ser

1st 1 2nd 3 3rd 100 4th 100 5th 100 dtype: int64 ser

1st 1 2nd 3 3rd 5 4th 7 5th 9

dtype: int64

ser + ser

1st 2 2nd 6 3rd 10 4th 14 5th 18 dtype: int64

ser / 2

1st 0.5 2nd 1.5 3rd 2.5 4th 3.5 5th 4.5 dtype: float64 ser

1st 1 2nd 3 3rd 5 4th 7 5th 9

ser.mean()

dtype: int64

5.0

np.mean(ser)

5.0

01 01 01

PANDAS

Series

```
>>> import pandas as pd
>>> s = pd.Series(list('abcdef'))
>>> 5
     а
     b
     d
>>> s = pd.Series([2, 4, 6, 8])
>>> S
     8
```

Series-Indexing

```
>>> s = pd.Series([2, 4, 6, 8],
index = ['f', 'a', 'c', 'e'])
>>>
>>> s['a']
>>> s[['a', 'c']]
```

01 01

PANDAS

Series-Indexing

```
>>> s2 = pd.Series(range(4),
index = list('abab'))
>>> s2
>>> s['a]
>>>
>>> s['a']
>>> s2['a']
>>> s2['a'][0]
```

01 01 01 01

PANDAS

Series-Operations

```
>>> s[s > 4]
>>> 5>4
     False
     False
      True
      True
>>> s*2
      8
а
     12
     16
```

01 01 01

PANDAS

Series-Incomplete Data

```
>>> sdata = {'b':100, 'c':150, 'd':200}
>>> s = pd.Series(sdata)
>>> 5
     100
     150
     200
>>> s = pd.Series(sdata, list('abcd'))
>>> 5
     NaN
     100
     150
     200
>>> 5*2
     NaN
     200
     300
     400
```

01 01 01

PANDAS

Series- Automatic Alignment

```
>>> s2 = pd.Series([1, 2, 3],
index = ['c', 'b', 'a'])
>>> 52
>>> 5
     NaN
     100
     150
     200
>>> 5*52
     NaN
     200
     150
     NaN
```

Output

40

Output


'NewDelhi'




Slicing

Output

Paris
USA WashingtonDC
UK London
dtype: object









df = pd.DataFrame ({ 'month' : [2, 5, 8, 10], 'year' : [2017, 2019, 2018, 2019], 'sale' : [60, 45, 90, 36] })




DataFrame

df	month	year	sale
0	2	2017	60
1	5	2019	45
2	8	2018	90
3	10	2019	36




DataFrame	one	two	three
tiger	2	3	4
lion	5	6	7














01 01 01

PANDAS

```
>>> data = {'state': ['FL', 'FL', 'GA', 'GA', 'GA'],
           'year': [2010, 2011, 2008, 2010, 2011],
           'pop': [18.8, 19.1, 9.7, 9.7, 9.8]}
>>> frame = pd.DataFrame(data)
>>> frame
   pop state year
  18.8 FL 2010
  19.1 FL
              2011
  9.7 GA
              2008
  9.7 GA
              2010
   9.8
       GA
              2011
```

01 01 01 01

PANDAS

01 01 01

PANDAS

```
>>> obj = pd.Series(['blue', 'purple', 'red'],
index=[0,2,4])
>>> obj
      blue
     purple
        red
>>> obj.reindex(range(4))
      blue
       NaN
     purple
       NaN
>>> obj.reindex(range(5), fill_value='black')
      blue
      black
     purple
     black
        red
>>> obj.reindex(range(5), method='ffill')
      blue
      blue
    purple
     purple
        red
```

01 01 01 01

PANDAS

```
>>> pop
        FL
             GA
2008
       NaN
            9.7
2010
     18.8
           9.7
2011
     19.1 9.8
>>> pop.sum()
FL
      37.9
GA
      29.2
>>> pop.mean()
      18.950000
FL
GA
       9.733333
>>> pop.describe()
              FL
                         GA
        2.000000
                  3.000000
count
       18.950000
                  9.733333
mean
        0.212132
std
                  0.057735
min
       18.800000
                  9.700000
25%
       18.875000
                  9.700000
50%
       18.950000
                  9.700000
75%
       19.025000
                  9.750000
       19.100000
                  9.800000
max
```

01 01 01

PANDAS

```
>>> pop
       FL
           GΑ
2008
     NaN
           9.7
     18.8
2010
           9.7
2011
    19.1 9.8
>>> pop < 9.8
        FL
               GΑ
    False
2008
            True
2010
    False True
    False False
2011
>>> pop[pop < 9.8] = 0
>>> pop
       FL
            GA
2008
     NaN
           0.0
2010
     18.8
           0.0
2011
     19.1
           9.8
```